

学校代码: 10385

分类号: _____

本科生学号: _____

密 集: _____



华侨大学
HUAQIAO UNIVERSITY

硕士专业学位论文

华侨大学硕士本科生论文 $\text{\LaTeX}$ 模版
 $\text{\LaTeX}$ Thesis Template for Huaqiao University

作者姓名: 陈一锋

指导教师: 李 四 教 授

学 科: 土木工程

研究方向: 结构体系创新与工程应用

所在学院: 土木工程学院

论文提交日期: 二〇一八年五月二十八日

学 位 论 文 答 辩 委 员 会 决 议

根据《中华人民共和国学位条例》、《中华人民共和国学位条例暂行实施办法》、《华侨大学学位授予工作细则》及《华侨大学研究生学位论文质量监控与评阅答辩的管理规定》的规定，学位论文答辩委员会经充分交换意见，对论文做出评价，并以无记名投票方式进行表决，同意该同学通过硕士学位论文答辩，同意授予硕士学位。

答辩委员会(主席签字): _____

答辩时间: _____ 年 ____ 月 ____ 日

学位论文独创性声明

本人声明兹呈交的学位论文是本人在导师指导下完成的研究成果。论文写作中不包含其他人已经发表或撰写过的研究内容，如参考他人或集体的科研成果，均在论文中以明确的方式说明。本人依法享有和承担由此论文所产生的权利和责任。

论文作者签名：_____ 签名日期：_____

学位论文版权使用授权声明

本人同意授权华侨大学有权保留并向国家机关或机构送交学位论文的复印件和电子版，允许学位论文被查阅和借阅。本人授权华侨大学可以将本学位论文的全部内容或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

论文作者签名：_____ 指导老师签名：_____

签 名 日 期：_____ 签 名 日 期：_____

摘 要

$\text{\LaTeX}$ 是一种强大的排版系统，该系统提供了丰富的功能，包括自动编号、交叉引用、数学公式排版、参考文献管理等。它还支持多种文档类、宏包和模板，使用户能够根据自己的需求定制文档的外观和格式，广泛用于撰写学术论文、科技文档和出版物。本文主要以前期准备、图表设置、使用 Zotero 管理参考文献、 $\text{\LaTeX}$ 部分所需包介绍、附录和参考格式等环节进行介绍。首先在前期准备中介绍了 Git 的相关内容以及 VS Code 的配置。此外，还介绍了文件和标签的命名规则，为编写论文的命名提供参考，并对在 $\text{\LaTeX}$ 中的图表设置以例子详细说明如何在论文中插入和设置图表，涵盖了图片的插入、标注、引用和交叉引用等方面的技巧和方法，也对如何使用 Zotero 管理参考文献进行了介绍说明。最后，在附录部分给出了参考格式的理解说明。通过阅读本文，读者将获得关于前期准备、图表设置、参考文献管理、 $\text{\LaTeX}$ 必需包、附录和参考格式的全面指导，有助于顺利完成论文写作和格式规范要求。

关键词： $\text{\LaTeX}$ ；模板学习

目 录

第 1 章 绪论	1
1.1 研究背景和意义	1
1.2 国内外研究现状	2
1.3 本文研究内容和组织结构	2
第 2 章 深度 Ritz 计算方法	5
2.1 一维拉压杆模型的计算方法	5
2.2 Ritz 方法	7
2.3 深度 Ritz 方法	8
2.4 数值结果	10
第 3 章 伽辽金无网格法	13
3.1 弱形式推导	13
3.2 无网格离散化	13
3.3 离散弱形式	15
3.4 拉格朗日乘子法	16
3.5 高斯积分法	17
3.6 数值结果	18
第 4 章 再生核近似增强深度 Ritz 方法	21
4.1 再生核近似增强	21
4.1.1 标准深度 Ritz 方法	21
4.1.2 增强机制: MLS 形函数	21
4.1.3 神经网络模块与特征拼接	21
4.2 模块整合	22
4.3 训练算法	23
4.4 数值结果	23
4.4.1 对比 Deep Ritz 方法	24
4.4.2 计算时间对比	26

4.4.3 对比 RKPM 方法	27
第 5 章 结论	29
第 6 章 使用 Zotero 管理参考文献	31
参考文献	33
个人简历、在学期间发表的学术论文与研究成果	35

第1章 绪论

1.1 研究背景和意义

有限元法通过将问题的求解区域离散为有限单元并按一定方式连接，利用每个单元的近似函数分片表达未知场函数，并利用加权余量法等原理建立各节点量的关系式，最后通过一定算法求解方程组得到原问题的解。有限元法作为一种通用灵活的解法广泛使用，但随着对象的复杂程度增加，暴露了许多问题，如网格单元剖分，大变形问题网格畸变等，因此在有限元法的基础上针对网格存在的问题提出了一类新的方法，即无网格法。

无网格法通过对求解域内采用一系列节点排列以及核函数近似，使得所求域上节点可以影响研究对象上任意一点的力学特性，只需要节点位置信息而不依赖节点间的有序单元连接，能够生成任意高阶连续的整体协调形函数。与传统有限元法相比，无网格法在求解大变形问题、移动边界问题和高阶问题时具有显著优势，尤其适用于土木工程中的复杂数值计算。伽辽金型无网格法是目前应用最广泛的无网格法分支之一，其基于弱形式的数值离散在理论上兼具高精度和高灵活性。然而，伽辽金型无网格法的形函数通常不具备多项式特性，且具有非插值性，影响域与背景积分网格往往不重合，导致数值积分需依赖高阶高斯积分。这使得计算效率低下，难以高效处理土木工程中的大型实际问题。因此，如何提升伽辽金型无网格法的计算效率成为算法研究领域的核心挑战之一。

近年来，深度学习技术的兴起为数值解算提供了新视角。深度利兹法（Deep Ritz Method）通过神经网络直接优化变分问题的能量泛函，无需显式网格划分，在复杂边界条件和高维问题的求解中展现出独特优势。然而，传统深度利兹法在高阶问题中的收敛性不足、对网络训练参数敏感，导致其在土木工程复杂场景下的解算精度和稳定性有待优化。再生核近似作为伽辽金型无网格法的重要理论基础，以其高精度逼近和插值能力，为增强深度学习模型提供了潜力。如何将再生核近似的高阶特性与深度利兹法的优化能力相结合，成为提升数值解算性能的关键问题。

本文提出基于再生核近似的增强深度利兹法，旨在优化传统深度学习模型在土木工程问题中的数值解算效果。通过将再生核近似融入深度利兹法的神经

网络框架，本研究不仅探索其理论可行性，还分析其在精度、效率和稳定性方面的改进效果。研究总结了伽辽金型无网格法中再生核近似的基本原理，结合深度利兹法的变分求解特点，探讨两者融合在土木工程数值计算中的应用前景。本方法的提出旨在为复杂工程问题的解算提供高效、稳定的算法支持，推动数值计算领域的理论与实践发展。

1.2 国内外研究现状

伽辽金型无网格法是无网格方法的重要分支，以高阶光滑性和复杂问题适应性著称。Belytschko 等人于 1994 年提出伽辽金无单元法 (Element Free Galerkin Method, EFG)，基于移动最小二乘近似构造形函数，通过背景网格和高阶积分提升精度。此后，Liu 等人于 1995 年提出再生核近似 (Reproducing Kernel Approximation, RK)，通过多项式再生条件和校正函数改进逼近能力，发展出再生核质点法 (RKPM)，显著增强了数值稳定性 (Liu, 1995)。再生核理论在数值逼近、插值和数据拟合中具有显著优势。深度利兹法 (Deep Ritz Method) 由 E W 和 Yu B 于 2017 年提出，利用深度神经网络最小化变分问题的能量泛函，为偏微分方程求解提供了新途径 (E W, 2017)。该方法无需网格划分，在处理复杂边界条件和高维问题时表现出灵活性。本文旨在探讨再生核近似的理论基础及其在增强深度利兹法中的应用效果，为土木工程中的数值计算和模型预测提供创新性方法。

1.3 本文研究内容和组织结构

本文旨在研究并实现一种基于再生核近似的增强深度利兹法，优化传统深度学习模型在土木工程问题中的数值解算效果，重点针对一维拉压杆等弹性力学问题的微分方程求解，探索其在复杂工程场景中的应用潜力。研究内容涵盖理论分析、方法介绍及算法创新，围绕一维拉压杆问题展开系统研究，同时为更广泛的土木工程数值计算提供支持。

本文第一部分从一维拉压杆问题的微分方程求解入手，基于弹性力学原理分析其控制微分方程及其边界条件。通过建立明确的数学模型，为后续数值方法的验证提供基础算例。

本文第二部分介绍深度利兹法的理论与应用，阐释其通过神经网络最小化

能量泛函的变分求解原理，分析其在土木工程数值解算中的适用性。以一维拉压杆问题为例，设计数值算例，验证传统深度利兹法的解算精度与效率，同时识别其高阶问题中的局限性，为后续改进提供依据。

本文第三部分介绍伽辽金型无网格法的理论与实践，阐述其基于节点构造高阶形函数的基本原理，重点分析数值积分的实现方式。以一维拉压杆问题为算例，验证伽辽金无网格法（如再生核质点法）的逼近能力和稳定性，探讨其计算复杂度与边界处理问题，为增强方法的开发提供参考。

本文第四部分研究基于再生核近似的增强深度利兹法。分析再生核近似的高精度逼近特性与深度利兹法的变分求解原理，推导两者结合的数学框架，探索增强深度利兹法的理论可行性。利用 Python 编程设计增强算法模型，将再生核形函数融入神经网络结构，改进损失函数，在数值验证与分析中，以一维拉压杆问题为对象，验证增强方法的性能。

第 2 章 深度 Ritz 计算方法

本章运用深度 Ritz 方法对一维线弹性夹紧板模型进行数值计算，深度 Ritz 方法其核心思想是将变分问题转化为优化问题，通过深度学习框架高效求解偏微分方程。即通过构造一个神经网络来逼近问题的解，利用变分原理将 PDE 的满足转化为能量泛函的最小化问题，从而避免了传统数值方法中网格划分的复杂性。本章最后针对一维拉压杆问题进行数值分析以及数值实验。

2.1 一维拉压杆模型的计算方法

平衡微分方程

考虑一均匀等截面杆，长度为 l ，横截面积为 A ，弹性模量为 E 。杆的左端固定（位移为零），右端施加拉力 F ，杆整体施加单位长度的体力 q （假设为常数）。取一微元体，考虑微元的受力平衡：左侧轴力 $N(x)$ ，方向为 x 轴负方向；右侧轴力 $N(x+dx)$ ，方向为 x 轴正方向。由 x 方向的平衡方程有：

$$N(x+dx) - N(x) + q dx = 0 \quad (2.1)$$

取极限得：

$$\frac{dN}{dx} = q \quad (2.2)$$

代入轴力表达式：

$$N = EA \frac{du}{dx} \quad (2.3)$$

方程形式：

$$\frac{d}{dx} \left(EA \frac{du}{dx} \right) = q \quad (2.4)$$

若 EA 为常数，则：

$$\frac{d^2 u}{dx^2} = \frac{q}{EA} \quad (2.5)$$

边界条件

左端固定：

$$u(0) = 0 \quad (2.6)$$

右端施加拉力：

$$N(l) = EA \frac{du}{dx} \Big|_{x=l} = F \quad (2.7)$$

因此对于一维拉压杆模型，其强形式表达式可写为：

$$\begin{cases} EA \nabla^2 u - q = 0 & \text{in } (0, l) \\ u = 0 & \text{on } x = 0 \\ EA \nabla u = F & \text{on } x = l \end{cases} \quad (2.8)$$

解析解的推导

对 (2.5) 进行积分：

1. 第一次积分：

$$\frac{du}{dx} = \int \frac{q}{EA} dx + C_1 = \frac{q}{EA} x + C_1 \quad (2.9)$$

2. 第二次积分：

$$u(x) = \int \left(\frac{q}{EA} x + C_1 \right) dx + C_2 = \frac{q}{2EA} x^2 + C_1 x + C_2 \quad (2.10)$$

应用边界条件：

1. *Dirichlet* 边界条件 $u(0) = 0$ ：

$$u(0) = \frac{q}{2EA} \cdot 0^2 + C_1 \cdot 0 + C_2 = 0 \implies C_2 = 0$$

因此：

$$u(x) = \frac{q}{2EA} x^2 + C_1 x \quad (2.11)$$

2. *Neumann* 边界条件 $N(l) = F$ ：

$$\frac{du}{dx} = \frac{q}{EA} x + C_1, \quad N(l) = EA \left(\frac{q}{EA} l + C_1 \right) = ql + EAC_1 = F$$

$$C_1 = \frac{F - ql}{EA}$$

代入 C_1 ：

$$u(x) = \frac{q}{2EA} x^2 + \frac{F - ql}{EA} x \quad (2.12)$$

2.2 Ritz 方法

变分法在解决边界值问题中发挥着至关重要的作用，其核心思想在于通过构建一个泛函并寻找其极值来间接找到方程的解。Ritz 法是一种常用的近似解法。根据最小势能原理，如果能够列出所有的几何可能位移，那么使总势能取最小值的那一组位移就是真实位移。

以一维泊松方程为例，其强形式为：

$$-\frac{d^2u}{dx^2} = f(x), \quad x \in (0, 1) \quad (2.13)$$

并施加 Dirichlet 边界条件 $u(0) = 0, u(1) = 0$ 。为了将其转化为泛函最小值问题，首先构造弱形式。

乘以测试函数 $v \in H_0^1(0, 1)$ (满足边界条件 $v(0) = v(1) = 0$)，并对定义域积分：

$$\int_0^1 -\frac{d^2u}{dx^2} v \, dx = \int_0^1 f v \, dx \quad (2.14)$$

使用分部积分：

$$\int_0^1 -\frac{d^2u}{dx^2} v \, dx = \left[-\frac{du}{dx} v \right]_0^1 + \int_0^1 \frac{du}{dx} \frac{dv}{dx} \, dx$$

由于 $v(0) = v(1) = 0$ ，边界项消失，得到弱形式：

$$\int_0^1 \frac{du}{dx} \frac{dv}{dx} \, dx = \int_0^1 f v \, dx \quad (2.15)$$

弱形式的解 u 等价于使以下能量泛函取最小值：

$$J[u] = \int_{\Omega} \left(\frac{1}{2} |\nabla u|^2 - f u \right) d\Omega \quad (2.16)$$

即求解微分方程等价于寻找使 $J[u]$ 最小的函数 u 。Ritz 法通过将假设的解代入泛函中，构造关于假设解参数的表达式，通过优化参数使泛函达到极值，实现泛函最小化。例如：

选择一组满足边界条件的基函数（如多项式、三角函数或分段多项式），构造近似解：

$$u_h(x) = \sum_{i=1}^n c_i \phi_i(x) \quad (2.17)$$

其中 c_i 为待定系数， $\phi_i(x)$ 是基函数。

将近似解代入泛函，得到关于系数的多元函数：

$$J(c_1, c_2, \dots, c_n) = \int_{\Omega} \left(\frac{1}{2} \left| \nabla \sum c_i \phi_i \right|^2 - f \sum c_i \phi_i \right) d\Omega \quad (2.18)$$

展开泛函：

$$\begin{aligned}\nabla u_h &= \nabla \left(\sum_{i=1}^n c_i \phi_i \right) = \sum_{i=1}^n c_i \frac{d\phi_i}{dx} \\ |\nabla u_h|^2 &= \left(\sum_{i=1}^n c_i \frac{d\phi_i}{dx} \right) \left(\sum_{j=1}^n c_j \frac{d\phi_j}{dx} \right) = \sum_{i=1}^n \sum_{j=1}^n c_i c_j \frac{d\phi_i}{dx} \frac{d\phi_j}{dx}\end{aligned}$$

代入泛函：

$$J(c_1, c_2, \dots, c_n) = \int_0^1 \left(\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n c_i c_j \frac{d\phi_i}{dx} \frac{d\phi_j}{dx} - f \sum_{i=1}^n c_i \phi_i \right) dx$$

定义刚度矩阵 K 和载荷向量 $\mathbf{f}$ ：

$$K_{ij} = \int_0^1 \frac{d\phi_i}{dx} \frac{d\phi_j}{dx} dx, \quad f_i = \int_0^1 f \phi_i dx$$

泛函变为二次型：

$$J(\mathbf{c}) = \frac{1}{2} \mathbf{c}^T K \mathbf{c} - \mathbf{f}^T \mathbf{c} \quad (2.19)$$

其中 $\mathbf{c} = [c_1, c_2, \dots, c_n]^T$, K 为对称正定矩阵 (因 $K_{ij} = K_{ji}$, 且 $\mathbf{c}^T K \mathbf{c} = \int_0^1 |\nabla u_h|^2 dx \geq 0$), $\mathbf{f} = [f_1, f_2, \dots, f_n]^T$ 。

对 $J(\mathbf{c})$ 求极值, 即对 $\mathbf{c}$ 求导：

$$\frac{\partial J}{\partial \mathbf{c}} = K \mathbf{c} - \mathbf{f} = 0$$

得到线性方程组：

$$K \mathbf{c} = \mathbf{f} \quad (2.20)$$

解此方程组即得最优系数 $\mathbf{c}$, 从而确定近似解 $u_h(x)$ 。

2.3 深度 Ritz 方法

有限元方法 (FEM)、虚拟元方法 (VEM) 都受网格剖分的限制, 只有当网格剖分达到足够精细的程度时, 才能满足计算精度的要求, 这将不可避免增加计算的时间和成本。但深度 Ritz 法不受网格剖分的限制, 传统方法中, 基函数是预先选定的, 深度 Ritz 方法用神经网络作为基函数的表示, 即由深度神经网络定义的非线性变换。选择能量泛函作为损失函数, 通过优化神经网络参数来最小化泛函, 从而代替方程求解。

构建网络是深度 Ritz 的关键环节, 其网络的每一层结构是通过将多个块进行叠加来构建的。每个块内部包含两个线性变换、两个激活函数以及一个残差连接, 残差连接使网络更容易训练, 而且有助于避免梯度消失问题。

在第一个全连接层后，输入 X 的维数由原定值转化为 m ，这样可以增加网络中的权重，以此来提高网络的准确性。网络中的第一个全连接层对应的函数为：

$$h_0 = W_0 X + b_0 \quad (2.21)$$

第 i 个块的工作流程如下：

$$h_i = h_{i-1} + \sigma(W_{i2}\sigma(W_{i1}h_{i-1} + b_{i1}) + b_{i2}) \quad (2.22)$$

其中， W_{ij} 是块的权重， σ 是激活函数。

完整的 n 层网络可以表示为：

$$u_\theta(x) = W_n h_{n-1} + b_n \quad (2.23)$$

其中 θ 表示整个网络中的权重。在得到 $u_\theta(x)$ 后，可以通过以下式子获得：

$$J(\theta) = \int_{\Omega} \left(\frac{1}{2} |\nabla u_\theta|^2 - f u_\theta \right) d\Omega \quad (2.24)$$

通过将其最小化得到优化了参数 θ^* 的就是所求得目标：

$$\theta^* = \arg \min_{\theta} J(\theta) \quad (2.25)$$

与经典的基于网格的正交规则（如梯形规则和辛普森规则）不同，蒙特卡洛算法不受维数灾难的影响，在高维情况下可以良好平稳地工作。但直接计算泛函中积分是相当困难的，所以用蒙特卡洛算法来对泛函进行离散：

$$J(\theta) \approx \frac{|\Omega|}{N} \sum_{i=1}^N \left(\frac{1}{2} |\nabla u_\theta(x_i)|^2 - f(x_i) u_\theta(x_i) \right) \quad (2.26)$$

蒙特卡洛方法的核心思想是通过随机采样来估计这个积分的值。

为了高效处理这种情况，我们选择了随机梯度下降（SGD）方法作为解决方案。其中， x_i 是均匀分布在 Ω 上的独立同分布随机变量。损失函数被用来估计神经网络的输出与真实值之间的差异，并为神经网络中的参数优化提供方向。在神经网络反向传播过程中，选择 Adam 优化器，逐层更新参数，使损失函数逐渐减小，直到收敛。

2.4 数值结果

考虑两端固定的一维弹性杆问题：

$$\begin{cases} -\nabla^2 u = -1, & x \in (0, 1) \\ u(0) = 0 \\ u(1) = 1 \end{cases} \quad (2.27)$$

该问题的解析解为

$$u(x) = \frac{1}{2}x^2 + \frac{1}{2}x \quad (2.28)$$

本章构建的神经网络基于一个简单的多层感知机结构，具有一个输入层、一个隐藏层和一个输出层，分别对应 1 维输入和 1 维输出，隐藏层的宽度 m 为 50。本次用于近似一维微分方程的网络是由一个块（两个全连接层）、一个输入层和一个输出层组成的。

边界条件会导致一些问题，通过在损失函数中加入边界条件的残差项，强制网络解在边界处逼近给定值，作为惩罚项来间接强制网络满足边界条件。本章边界损失通过 1000 倍的惩罚系数来增强。

对应于体积分损失，通过蒙特卡洛方法（随机采样点）近似积分：

$$L_{\text{vol}} = \frac{1}{N} \sum_{i=1}^N \left(\frac{1}{2} |\nabla u_{\theta}(x_i)|^2 - f(x_i) u_{\theta}(x_i) \right) \quad (2.29)$$

对应于边界条件损失：

$$L_{\text{bdy}} = \frac{1}{M} \sum_{j=1}^M |u_{\theta}(x_j) - g(x_j)|^2 \quad (2.30)$$

总损失为：

$$L = L_{\text{vol}} + 1000 \cdot L_{\text{bdy}} \quad (2.31)$$

对该问题采用 20000 次迭代的梯度下降，使用 Adam 优化器，初始学习率为 0.001，并通过 StepLR 调度器以每 5000 步减少至原来的 30% 来优化学习率。

为了更定量地分析误差，考虑解析解，用均方误差来近似误差：

$$\text{误差} = \int_{\Omega} |u_{\text{exact}}(x) - u_{\theta^*}(x)|^2 dx \quad (2.32)$$

计算误差如下：




图 2.1 训练过程与结果可视化

结果分析

Deep Ritz 方法在一维问题中表现出色，绝对误差保持在 10^{-3} 数量级，最大误差 0.008 出现在 $x \approx 0.8$ 附近（图 2.1a），显示出较高的精度，但中间区域误差略高可能与网络捕捉高阶导数能力不足有关。初期损失从 300 快速下降至 1.78，后期平滑收敛至 0.96（图 2.1b），表明其计算效率高且优化稳定。相比传统有限元法，Deep Ritz 无需网格划分即可达到较低误差，计算复杂度集中于初期训练，适合高维问题和复杂几何场景，在避免维度灾难和处理非规则边界方面具有显著潜力。




图 2.2 拟合失败情况

深度 Ritz 方法在 1000 步训练时的拟合失败情况显著，如（图 2.2a）所示，预测解（蓝色曲线）与精确解（橙色曲线）存在明显偏差。这表明模型在有限迭代步数下未能充分收敛，说明训练步数不足以优化网络参数 θ ，权重未适配短时训练。相比之下，10000 步训练（图 2.2b）显示预测解与精确解几乎重合，验证了深度 Ritz 法迭代次数的重要性。

第3章 伽辽金无网格法

3.1 弱形式推导

考虑强形式 (2.8) 对应的势能泛函表达式，系统的总势能 $\Pi(\mathbf{x})$ 可表示为内部能量与外部能量的差：

$$\Pi(\mathbf{x}) = \underbrace{\int_{\Omega} \frac{1}{2} \boldsymbol{\sigma} : \boldsymbol{\varepsilon} d\Omega}_{\text{内部能量}} - \underbrace{\left(\int_{\Gamma_t} \mathbf{u} \cdot \mathbf{t} d\Gamma + \int_{\Omega} \mathbf{u} \cdot \mathbf{b} d\Omega \right)}_{\text{外部能量}} \quad (3.1)$$

令上式的变分为零，即 $\delta\Pi(\mathbf{x}) = 0$ ，可得对应的伽辽金弱形式：

$$\int_{\Omega} \delta \boldsymbol{\sigma} : \boldsymbol{\varepsilon} d\Omega = \int_{\Gamma_t} \delta \mathbf{u} \cdot \mathbf{t} d\Gamma + \int_{\Omega} \delta \mathbf{u} \cdot \mathbf{b} d\Omega \quad (3.2)$$

其中， $\delta u(0)$ 是虚位移， $\delta u(0) = 0$ ，满足 *Dirichlet* 条件。

3.2 无网格离散化

构造无网格形函数

再生核近似方法的目的是通过离散点近似连续函数 $u(x)$ 。其连续形式为：

$$u^h(x) = \int_{\Omega} \Phi(x - x') u(x') d\Omega' \quad (3.3)$$

其中， $\Phi(x - x_I)$ 表示核函数，用于定义形函数的权重分布，通常具有有限支撑（如三次样条核函数），衡量点 x 与节点 x_I 之间的距离影响。离散化为：

$$u^h(x) = \sum_{I=1}^N \Phi(x_I - x) u(x_I) \Delta V_I \quad (3.4)$$

为保证多项式再生性，修正为：

$$u^h(x) = \sum_{I=1}^N \Psi_I(x) u_I \quad (3.5)$$

其中，形函数定义为：

$$\Psi_I(x) = \mathbf{p}^T(x) \mathbf{b}(x) \Phi(x_I - x) \Delta V_I \quad (3.6)$$

$\Psi_I(x)$ 是最终的形函数，通过引入多项式基 $\mathbf{p}(x)$ 和校正系数 $\mathbf{b}(x)$ 确保再生多项式特性。 $\mathbf{p}(x)$ 通常为线性基（如 $[1, x]^T$ ）， $\mathbf{b}(x)$ 通过再生条件（如 $\sum_I \Psi_I(x) = 1$ 和 $\sum_I \Psi_I(x) x_I = x$ ）确定， ΔV_I 表示节点 x_I 的体积权重。

再生条件

要求 $u^h(x)$ 再生 m 阶多项式:

$$\sum_{I=1}^N \Psi_I(x) p_k(x_I) = p_k(x), \quad k = 0, 1, \dots, m \quad (3.7)$$

代入 (3.6):

$$\sum_{I=1}^N \mathbf{p}^T(x) \mathbf{b}(x) \Phi(x_I - x) p_k(x_I) \Delta V_I = p_k(x) \quad (3.8)$$

定义矩量矩阵:

$$\mathbf{M}(x) = \sum_{I=1}^N \Phi(x_I - x) \mathbf{p}(x_I) \mathbf{p}^T(x_I) \Delta V_I \quad (3.9)$$

则:

$$\mathbf{p}^T(x) \mathbf{b}(x) \mathbf{M}(x) = \mathbf{p}^T(x) \quad (3.10)$$

解得:

$$\mathbf{b}(x) = \mathbf{M}^{-1}(x) \mathbf{p}(x) \quad (3.11)$$

无网格形函数

代入 (3.6):

$$\Psi_I(x) = \mathbf{p}^T(x_I) \mathbf{M}^{-1}(x) \mathbf{p}(x) \Phi(x_I - x) \Delta V_I \quad (3.12)$$

此形函数满足 m 阶多项式再生性。为了验证数值近似 $\mathbf{A}(x)$ 的性状, 可以采用移动基函数 $\mathbf{p}(x_I - x)$ 。将其代入 (3.5) 得出如下再生条件:

$$\sum_{I=1}^{NP} \Psi_I(x) \mathbf{p}(x_I - x) = \mathbf{p}(0) \quad (3.13)$$

此时假设:

$$\Psi_I(x) = \mathbf{p}^T(x_I - x) \mathbf{c}(x) \phi(x_I - x) \quad (3.14)$$

将表达式 (3.14) 代入 (3.13), 有:

$$\mathbf{c}(x) = \mathbf{A}^{-1}(x) \mathbf{p}(0) \quad (3.15)$$

由此, 采用移动基函数 $\mathbf{p}(x - x_I)$ 的无网格形函数为:

$$\Psi_I(x) = \mathbf{p}^T(0) \mathbf{A}^{-1}(x) \mathbf{p}(x_I - x) \phi(x_I - x) \quad (3.16)$$

位移和应变离散化

使用再生核近似:

$$u^h(x) = \sum_{I=1}^N \Psi_I(x) u_I \quad (3.17)$$

形函数:

$$\Psi_I(x) = \mathbf{p}^T(x) \mathbf{M}^{-1}(x) \mathbf{p}(x_I) \Phi(x - x_I) \Delta V_I \quad (3.18)$$

其中, $\mathbf{p}(x) = [1, x]^T$, $\mathbf{M}(x) = \sum_{I=1}^N \Phi(x - x_I) \mathbf{p}(x_I) \mathbf{p}^T(x_I) \Delta V_I$ 。

应变为:

$$\varepsilon(x) = \frac{du^h}{dx} = \sum_{I=1}^N B_I(x) u_I, \quad B_I(x) = \frac{d\Psi_I(x)}{dx} \quad (3.19)$$

虚位移和虚应变:

$$\delta u^h(x) = \sum_{I=1}^N \Psi_I(x) \delta u_I, \quad \delta \varepsilon(x) = \sum_{I=1}^N B_I(x) \delta u_I \quad (3.20)$$

3.3 离散弱形式

将 (3.17) 和 (3.20) 代入 (3.2):

$$\int_0^l EA \left(\sum_{I=1}^N B_I(x) u_I \right) \left(\sum_{J=1}^N B_J(x) \delta u_J \right) dx = \int_0^l \left(\sum_{J=1}^N \Psi_J(x) \delta u_J \right) q dx + \left(\sum_{J=1}^N \Psi_J(l) \delta u_J \right) F$$

提取 δu_J :

$$\sum_{I=1}^N \left(\int_0^l EA B_I(x) B_J(x) dx \right) u_I = \int_0^l \Psi_J(x) q dx + \Psi_J(l) F \quad (3.21)$$

刚度矩阵定义为

$$K_{IJ} = \int_0^l EA B_I(x) B_J(x) dx \quad (3.22)$$

力向量定义为

$$f_J = \int_0^l \Psi_J(x) q dx + \Psi_J(l) F \quad (3.23)$$

伽辽金无网格离散方程为:

$$\mathbf{K} \mathbf{u} = \mathbf{f} \quad (3.24)$$

3.4 拉格朗日乘子法

由于无网格形函数通常不具有插值特性, 因此需要采用适当的方法施加强制边界条件, 拉格朗日乘子法是一种在数值方法中施加约束条件的强大工具, 广泛应用于有限元法、无网格法等场景。其核心在于通过构造增广泛函, 将原始问题的能量泛函与约束条件结合, 确保解同时满足物理方程和附加约束。

对原始能量泛函添加约束条件

考虑一般的偏微分方程问题, 其弱形式可表示为:

$$a(u, v) = l(v), \quad (3.25)$$

其中 $a(u, v)$ 是双线性形式, $l(v)$ 是线性形式, u 是解函数, v 是试函数。例如, 在弹性力学或热传导问题中, $a(u, v)$ 可能涉及梯度项积分, $l(v)$ 则对应外力或源项的积分。

假设问题需满足一组线性约束条件, 例如 Dirichlet 条件或其他物理约束, 形式为:

$$c_k(u) = q_k, \quad k = 1, 2, \dots, m, \quad (3.26)$$

其中 m 是约束数量, $c_k(u)$ 是线性泛函, q_k 是给定值。原始能量泛函 $J(u)$ 定义为:

$$J(u) = \frac{1}{2}a(u, u) - l(u). \quad (3.27)$$

为施加约束, 引入拉格朗日乘子 $\lambda = [\lambda_1, \lambda_2, \dots, \lambda_m]^T$, 构造增广泛函:

$$L(u, \lambda) = J(u) + \sum_{k=1}^m \lambda_k [c_k(u) - q_k]. \quad (3.28)$$

对 $L(u, \lambda)$ 取变分, 分别对 u 和 λ 求偏导并置零:

$$\delta L = a(\delta u, u) - l(\delta u) + \sum_{k=1}^m \lambda_k c_k(\delta u) = 0, \quad (3.29)$$

$$\delta L = \sum_{k=1}^m \delta \lambda_k [c_k(u) - q_k] = 0. \quad (3.30)$$

从而得到增广弱形式:

$$a(v, u) + \sum_{k=1}^m \lambda_k c_k(v) = l(v), \quad (3.31)$$

以及约束条件:

$$c_k(u) = q_k, \quad k = 1, 2, \dots, m. \quad (3.32)$$

此形式适用于任意线性约束，不限于特定物理问题或边界条件。

离散化

在数值方法中，解 u 和试函数 v 通过形函数离散表示为：

$$u^h(x) = \sum_{I=1}^{NP} \Psi_I(x) d_I, \quad v^h(x) = \sum_{I=1}^{NP} \Psi_I(x) v_I, \quad (3.33)$$

其中 NP 是节点总数， $\Psi_I(x)$ 是形函数， d_I 和 v_I 分别是节点系数。代入增广弱形式 (3.31)，得到：

$$\sum_{I=1}^{NP} v_I \left[\sum_{J=1}^{NP} a(\Psi_I, \Psi_J) d_J + \sum_{k=1}^m \lambda_k c_k(\Psi_I) - l(\Psi_I) \right] = 0. \quad (3.34)$$

由于 v_I 任意，方括号内每一项为零。约束条件离散为：

$$\sum_{J=1}^{NP} c_k(\Psi_J) d_J = q_k, \quad k = 1, 2, \dots, m. \quad (3.35)$$

引入以下矩阵和向量，刚度矩阵 $\mathbf{K}$ 、载荷向量 $\mathbf{f}$ 、约束矩阵 $\mathbf{G}$ 、拉格朗日乘子向量 $\boldsymbol{\lambda}$ 和约束向量 $\mathbf{q}$ ：

$$\begin{aligned} \mathbf{K} : K_{IJ} &= a(\Psi_I, \Psi_J), \\ \mathbf{f} : f_I &= l(\Psi_I), \\ \mathbf{G} &= \begin{bmatrix} c_1(\Psi_1) & c_1(\Psi_2) & \cdots & c_1(\Psi_{NP}) \\ c_2(\Psi_1) & c_2(\Psi_2) & \cdots & c_2(\Psi_{NP}) \\ \vdots & \vdots & \ddots & \vdots \\ c_m(\Psi_1) & c_m(\Psi_2) & \cdots & c_m(\Psi_{NP}) \end{bmatrix}^T, \\ \boldsymbol{\lambda} &= [\lambda_1, \lambda_2, \dots, \lambda_m]^T, \\ \mathbf{q} &= [q_1, q_2, \dots, q_m]^T. \end{aligned} \quad (3.36)$$

增广系统为：

$$\begin{bmatrix} \mathbf{K} & \mathbf{G} \\ \mathbf{G}^T & 0 \end{bmatrix} \begin{bmatrix} \mathbf{d} \\ \boldsymbol{\lambda} \end{bmatrix} = \begin{bmatrix} \mathbf{f} \\ \mathbf{q} \end{bmatrix}. \quad (3.37)$$

3.5 高斯积分法

数值实现中， $\mathbf{K}$ 和 $\mathbf{f}$ 的元素通常涉及积分，例如 $K_{IJ} = \int_{\Omega} \nabla \Psi_I \cdot \nabla \Psi_J dx$ 或 $f_I = \int_{\Omega} f \Psi_I dx$ 。这些积分无法解析求解，需采用高斯积分法近似。对于一维问

题，积分区间划分为单元 $[x_e, x_{e+1}]$ ，高斯积分公式为：

$$\int_{x_e}^{x_{e+1}} g(x) dx \approx \sum_{i=1}^{n_g} w_i g(x_i) \frac{h_e}{2}, \quad (3.38)$$

其中 $h_e = x_{e+1} - x_e$ 是单元长度， $x_i = \frac{x_{e+1} + x_e}{2} + \frac{h_e}{2} \xi_i$ ， ξ_i 和 w_i 分别是高斯积分点和权重， n_g 是积分点数。高斯积分的高效性在于， n_g 点公式可精确计算最高 $2n_g - 1$ 阶多项式的积分，适用于形函数的低阶性质。

通过在每个单元内应用高斯积分，计算局部贡献并组装到全局矩阵 $\mathbf{K}$ 和向量 $\mathbf{f}$ ，最终求解增广系统 (3.37)，得到节点解 $\mathbf{d}$ 和拉格朗日乘子 λ 。

3.6 数值结果

考虑(2.27)两端固定的一维弹性杆问题，即

$$\begin{cases} \nabla^2 u - q = 0 & \text{in } (0, l) \\ u(0) = u(1) = 0 \end{cases}$$

该问题的解析解为：

$$u(x) = \frac{x^2}{2} + \frac{x}{2} \quad (3.39)$$

采用再生核近似方法（RKPM）进行离散，具体参数如下：线性基函数取 $\mathbf{p}(x) = [1, x]^T$ ，确保形函数再生 1 阶多项式。节点数为 $NP = 11$ ，节点均匀分布于 $[0, 1]$ ，即 $x_I = \{0.0, 0.10, 0.20, \dots, 1.0\}$ 。形函数影响域为 $s = 0.2$ ，为节点间距 0.1 的 2 倍，保证足够覆盖。核函数采用三次样条核函数：

$$\Phi(r) = \begin{cases} \frac{2}{3} - 4r^2 + 4r^3 & r \leq 0.5 \\ \frac{4}{3} - 4r + 4r^2 - \frac{4}{3}r^3 & 0.5 < r \leq 1.0 \\ 0 & r > 1.0 \end{cases} \quad (3.40)$$

其中， $r = \frac{|x - x_I|}{s}$ 。

离散方程为：

$$\mathbf{K} \mathbf{u} = \mathbf{f} \quad (3.41)$$

由于 $u(0) = 0$ 是 Dirichlet 条件，需通过拉格朗日乘子法施加，增广系统为：

$$\begin{bmatrix} \mathbf{K} & \mathbf{G} \\ \mathbf{G}^T & 0 \end{bmatrix} \begin{bmatrix} \mathbf{u} \\ \lambda \end{bmatrix} = \begin{bmatrix} \mathbf{f} \\ 0 \end{bmatrix} \quad (3.42)$$




图 3.1 基于伽辽金型无网格方法的一维弹性杆问题数值结果

x	u_{exact}	u_{computed}	误差
0.000	0.000000	0.000000	0.000000
0.100	0.055000	0.054726	0.000274
0.200	0.120000	0.118594	0.001406
0.300	0.195000	0.193921	0.001079
0.400	0.280000	0.278816	0.001184
0.500	0.375000	0.373794	0.001206
0.600	0.480000	0.478903	0.001097
0.700	0.595000	0.593458	0.001542
0.800	0.720000	0.719886	0.000114
0.900	0.855000	0.850146	0.004854
1.000	1.000000	1.000000	0.000000

表 3.1 解析解与计算解的对比

RKPM 方法在简单一维问题上具有较高的精度，绝对误差在 $x = 0.9$ 处达到最大值 0.004，平均误差约为 0.001，整体误差保持在 10^{-3} 数量级，精度较高。与 Deep Ritz 方法相比，RKPM 方法的误差分布较为均匀。但 RKPM 方法的误差在边界附近（如 $x = 0.9$ ）较大，而 Deep Ritz 方法通过惩罚项能更有效地约束了边界条件。

第 4 章 再生核近似增强深度 Ritz 方法

4.1 再生核近似增强

4.1.1 标准深度 Ritz 方法

由第三章可知，标准深度 Ritz 方法基于变分原理求解 PDE，其核心是将试探函数表示为神经网络(2.23) $u_\theta(x) = W_n h_{n-1} + b_n$ ，记作：

$$u_\theta(x) = NN(x; \theta), \quad (4.1)$$

其中 $NN(x; \theta)$ 是一个全连接神经网络，输入为空间坐标 $x \in \mathbb{R}^d$ ，输出为标量 $u_\theta(x)$ ， θ 是网络参数。深度 Ritz 法的本质在于利用神经网络的通用逼近能力，通过最小化能量泛函来近似 PDE 的解。但其依赖全局坐标 x ，难以捕捉解的局部几何特性，同时通过惩罚项强制满足边界条件可能导致边界处误差较大。因此解的逼近可能需要更深的网络或更长的训练时间。这些不足促使了增强型方法的提出。

4.1.2 增强机制：MLS 形函数

增强型深度 Ritz 方法引入移动最小二乘法 (MLS) 形函数 $\Psi(x)$ 来改进试探函数。MLS 形函数已在第四章详细推导，这里简述其构造：给定节点集 $\{x_j\}_{j=1}^N$ ，形函数定义为：

$$u_h(x) = \sum_{j=1}^N \Psi_j(x) u_j, \quad (4.2)$$

满足单位分解性 $\sum_{j=1}^N \Psi_j(x) = 1$ 。其计算简化为：

$$\Psi(x) = p^T(x, x) A^{-1}(x) B(x), \quad (4.3)$$

形函数 $\Psi(x)$ 的输出形状为 $(batch_size, N)$ ，表示 x 对每个节点的插值权重。

4.1.3 神经网络模块与特征拼接

增强型 Ritz 方法的核心在于通过特征拼接整合 MLS 形函数与神经网络。试探函数构造为：

$$u_\theta(x) = NN(z(x); \theta), \quad z(x) = [x, \Psi(x)], \quad (4.4)$$

其中 $z(x)$ 是增强输入特征， $\oplus$ 表示拼接操作。

原始输入 x 的形状为 $(batchsize, d)$ ，在 $d = 1$ 的情况下为 $(batchsize, 1)$ ，表示采样点的坐标，提供全局位置信息。形函数 $\Psi(x)$ 的形状为 $(batchsize, N)$ ，其中每个元素 $\Psi_j(x)$ 表示 x 受节点 x_j 的影响程度，编码了局部几何特性。拼接过程在张量维度上沿特征轴（第 1 维）连接，形式为：

$$z(x) = [x_1, \Psi_1(x), \Psi_2(x), \dots, \Psi_N(x)], \quad (4.5)$$

其中 x_1 是 x 的第 1 维坐标（在一维情况下）。对于批量输入， $z(x)$ 的形状为 $(batchsize, 1 + N)$ 。 x 提供全局上下文，确保网络感知整体空间位置， $\Psi(x)$ 引入局部插值信息，使网络能够感知离散节点的分布以及支持域内的几何关系。拼接后的 $z(x)$ 是一个复合特征向量，融合了全局和局部信息，从而增强了网络的表达能力。这种增强机制通过 $\Psi(x)$ 的紧支撑性使网络对 x 附近节点的贡献更敏感，改善局部解的精度，同时形函数的单位分解性有助于将边界条件嵌入解中，减少对惩罚项的依赖。

增强型网络 $NN(z(x); \theta)$ 的结构包括输入层、隐藏层和输出层。输入层的维度为 $d + N$ （例如 $1 + N$ ），负责接受 $z(x)$ 作为输入。隐藏层由 L 层全连接网络组成，每层宽度为 $width$ ，其计算形式为：

$$h_{l+1} = \tanh(W_l h_l + b_l), \quad h_0 = z(x), \quad l = 0, 1, \dots, L-1, \quad (4.6)$$

其中 W_l 和 b_l 是可训练参数， $\tanh$ 函数提供非线性变换。输出层通过线性投影得到结果，形式为：

$$u_\theta(x) = W_L h_L + b_L, \quad (4.7)$$

输出标量 $u_\theta(x)$ 。这种结构确保了网络能够有效处理增强特征并生成 PDE 的近似解。

4.2 模块整合

增强型试探函数整合了 MLS 和神经网络：

$$u_\theta(x) = NN([x, \Psi(x)]; \theta),$$

其中 $\Psi(x) = p^T(x, x)A^{-1}(x)B(x)$ 。这种整合使网络同时具备局部插值（MLS）和全局非线性拟合（神经网络）的能力。

基于 Ritz 变分原理，损失函数简化为：

$$\mathcal{L}(\theta) = \frac{1}{N_b} \sum_{i=1}^{N_b} \left[\frac{1}{2} |\nabla u_\theta(x_i)|^2 - f(x_i) u_\theta(x_i) \right] + \lambda \left[u_\theta(0)^2 + (u_\theta(1) - 1)^2 \right], \quad (4.8)$$

其中 N_b 是内部采样点数， λ 是边界惩罚系数。详细推导见伽辽金无网格法章节。

4.3 训练算法

基于增强深度 Ritz 方法的大致步骤为

1. 初始化：设定网络参数 θ 、节点集 $\{x_I\}$ 、支持域 s 、学习率 η 。
2. 采样：随机生成内部点 $\{x_i^b\}$ 和边界点 $\{0, 1\}$ 。
3. 前向传播：计算 $\Psi(x_i^b)$ ，拼接特征 $z(x_i^b)$ ，输出 $u_\theta(x_i^b)$ 和 $\nabla u_\theta(x_i^b)$ 。
4. 损失计算：评估能量项和边界项，得到 $\mathcal{L}(\theta)$ 。
5. 优化：通过反向传播更新 θ ，重复直到收敛。

4.4 数值结果

考虑(2.27)两端固定的一维弹性杆问题，即

$$\begin{cases} \nabla^2 u - q = 0 & \text{in } (0, l) \\ u(0) = u(1) = 0 \end{cases}$$

该问题的解析解为：

$$u(x) = \frac{x^2}{2} + \frac{x}{2} \quad (4.9)$$

基于该一维问题构建一个深度神经网络，其中输入和输出维度分别为 1，网络包含宽度为 50 且深度为 1（总层数为 3）的全连接层，采用 tanh 激活函数；其次，利用 100 个内部采样点和 2 个边界点构造损失函数，其中体积分损失基于拉普拉斯方程的变分形式 $\int_0^1 \left(\frac{1}{2} |\frac{\partial u}{\partial x}|^2 - f u \right) dx$ 近似计算，边界损失通过惩罚系数 1000 强制满足 Dirichlet 边界条件 $u(0) = 0$ 和 $u(1) = 1$ ；然后，引入再生核增强模块，采用 11 个均匀分布的节点（间距 0.1）及支持域大小 0.2 的三次样条核函数，计算形状函数并将其与原始输入拼接，增强网络特征表达；最后，采用 Adam 优化器以初始学习率 0.001 并结合步长为 300、衰减因子 0.3 的 StepLR 调度器，在 10000 步训练中通过批量梯度下降优化损失函数，每 10 步记录一次误差，测试阶段则在 100 个积分点上评估 L^2 和 H^1 误差。

4.4.1 对比 Deep Ritz 方法

训练精度对比




图 4.1 1000 步误差可视化。

1000 步训练后深度 Ritz 方法的 L2 误差为 0.11，解的整体逼近精度较低。绝对误差分布呈现对称抛物线形状，误差集中在 $x = 0.2$ 到 $x = 0.8$ 的区域。相比之下，增强深度 Ritz 方法将 L2 误差降低至 0.002。绝对误差分布峰值更小，变化平滑，表明引入 EFG 形状函数显著提升了局部逼近能力。

1000 步训练后深度 Ritz 方法的梯度误差（红色曲线）远高于函数值误差（蓝色曲线），表明模型在捕捉解的导数方面表现较差。再生核增强后 H1 误差显著降低。尽管梯度误差仍高于函数值误差，但其幅度大幅减小，表明 EFG 提升了模型对解导数的逼近能力。




图 4.2 10000 步误差可视化

10000 步训练后，DeepRitz 方法的 L2 误差和 H1 误差分别为 0.016 和 0.080，相较 1000 步（0.25 和 0.5）显著降低，但中间区域 L2 误差较大，边界处导数误差显著；RK-DeepRitz 方法的 L2 误差和 H1 误差为 0.0024 和 0.049，相较 1000 步（0.1 和 0.2）显著降低，误差分布波动较多但整体更低，优于 DeepRitz。

误差收敛效果




图 4.3 1000 步误差收敛可视化

DeepRitz 方法初始 L2 误差和 H1 误差较高（2.0 和 1.75），前 200 步下降至

0.5 和 0.75，最终稳定在 0.25 和 0.5，但存在波动且导数拟合较弱；RK-DeepRitz 方法初始误差较低（1.4-1.6），收敛更快，最终误差降至 0.1 和 0.2，训练更稳定，H1 误差与 L2 误差差距较小，显示出再生核增强对函数值和导数拟合的显著改进。




图 4.4 10000 步误差收敛可视化

DeepRitz 方法经训练后误差显著降低，但导数拟合仍为瓶颈。RK-DeepRitz 方法收敛更快，精度更高。

4.4.2 计算时间对比





图 4.5 训练时间和计算时间对比


从图 4.5 可以看出，DeepRitz 方法的训练时间随步数增加显著增长，而 RK-DeepRitz 方法训练时间更长，反映了再生核增强引入的额外计算开销。

4.4.3 对比 RKPM 方法

训练精度对比




(a) RKPM 方法绝对误差




(b) 再生核增强 10000 步绝对误差

图 4.6 误差可视化。



(a) RKPM 方法 L2 误差



(b) 再生核增强 10000 步 L2 误差

图 4.7 L2 误差对比

RKPM 方法的误差分布平滑但边界处导数误差较大；RK-DeepRitz 方法的误差分布波动较大但精度更高，导数误差波动性强。RK-DeepRitz 结合深度学习显著提升了 L2 误差的拟合能力，但导数拟合较弱。

第 5 章 结论

本文提出的再生核增强深度 Ritz 法（RK-DeepRitz）融合深度学习与无网格方法，基于 Ritz 变分原理，通过再生核增强提升偏微分方程求解的精度与效率。方法在深度神经网络框架下引入再生核近似，针对一维问题实现显著的 L^2 误差降低，展现出较高的推理效率与应用潜力。

首先，深度 Ritz 方法以 Ritz 方法为基础，通过预定义基函数近似位移场，而深度 Ritz 方法利用神经网络替代试函数，验证了其数值有效性。其次，伽辽金无网格法（RKPM）从弱形式出发，通过无网格离散化构造形状函数，结合拉格朗日乘子法强制边界条件并采用高斯积分法近似积分，显示出较好的导数拟合能力。最后，本文主要实现再生核近似增强深度 Ritz 法，通过再生核近似机制增强局部解表达能力，验证了方法的优越性。

尽管增强方法性能优于原始深度 Ritz 方法，但 H^1 误差中的梯度误差仍较高。这可能是由于网络深度或宽度不足，或训练步数有限（1000 步可能不足以充分收敛）。建议增加训练步数（例如到 5000 或 10000 步）或调整超参数（如学习率、惩罚系数）以进一步优化梯度逼近。

RK-DeepRitz 方法在 L^2 误差上优于 RKPM 和 DeepRitz，在 H^1 误差上低于 DeepRitz 但高于 RKPM，中间区域精度更高，导数误差波动较大，边界处需优化。训练时间较长但计算时间远低于 RKPM，验证了推理效率优势，为复杂偏微分方程求解提供了高效工具。增强深度 Ritz 方法通过 EFG 形状函数提升表达能力，适合处理复杂梯度变化问题。增强方法性能优于原始方法，但 H^1 梯度误差仍较高，建议增加训练步数或调整超参数以优化梯度逼近。

第 6 章 使用 Zotero 管理参考文献

1. 下载附件：Better BibTex 链接：[Better BibTex 安装步骤](#)
2. 新建分类建立文件库：references
3. 右击该文件库-选择导出分类-以 Better BibTex 形式导出条目
4. 导出条目至与 Latex 文件相同路径
5. 在主文件 (ef:main.tex) 中添加：

```
\begin{document}
.....
\ bibliography { references } -- 导出文献的文件名
.....
\end{document}
```

eg: 基于赫林格-赖斯纳原理的变分一致型伽辽金无网格法^[1-2]相较于传统的本质边界条件施加方法能够有效提高计算精度和计算效率。

Latex 代码

eg: 基于赫林格-赖斯纳原理的变分一致型伽辽金无网格法 `\cite{Wu2022,wu2023}`

参考文献

- [1] 吴俊超, 吴新瑜, 赵珧冰, 王东东. 基于 Hellinger-Reissner 变分原理的一致高效无网格本质边界条件施加方法. 力学学报, 2022.
- [2] Wu J, Wu X, Zhao Y, Wang D. A rotation-free Hellinger-Reissner meshfree thin plate formulation naturally accommodating essential boundary conditions. Engineering Analysis with Boundary Elements, 2023, 154: 122-140.

个人简历、在学期间发表的学术论文与研究成果

个人简历

XXX, 女, 汉族, XXXX 年 XX 月 XX 日出生, XX 省 XXX 人。

XXXX 年 XX 月毕业于 XXXX 学校 XXXX 专业, 获得工学学士学位。

XXXX 年 XX 月至今就读于华侨大学土木工程学院土木水利专业, 攻读工学硕士学位。

在学期间发表的论文

- [1] 吴俊超, 邓俊俊, 王家睿, 等. 伽辽金型无网格法的数值积分方法 [J]. 固体力学学报, 2016, 3(37): 208-233.
- [2] 吴俊超, 邓俊俊, 王家睿, 等. 伽辽金型无网格法的数值积分方法 [J]. 固体力学学报, 2016, 3(37): 208-233.